1º WORKSHOP

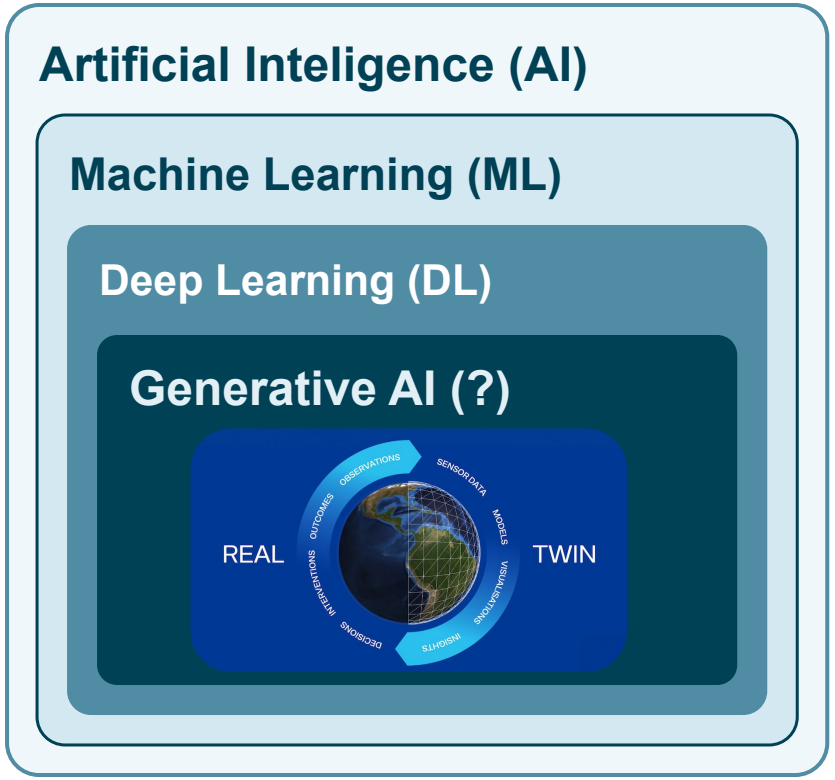
INCT ReNOMO

Machine Learning e Deep Learning na Oceanografia: avanços recentes e aplicações no INCT ReNOMO

André L. Belém | Universidade Federal Fluminense (UFF)
GT5 – Machine Learning aplicado à Oceanografia

Inteligência Artificial, Machine Learning e Deep Learning

Conceitos relacionados, mas não equivalentes



Artificial Intelligence (AI)

Campo abrangente de métodos computacionais para tarefas de percepção, inferência, decisão e geração.

Machine Learning (ML)

Aprendizado de relações e padrões a partir de dados.

Deep Learning (DL)

Métodos de ML baseados em redes neurais profundas.

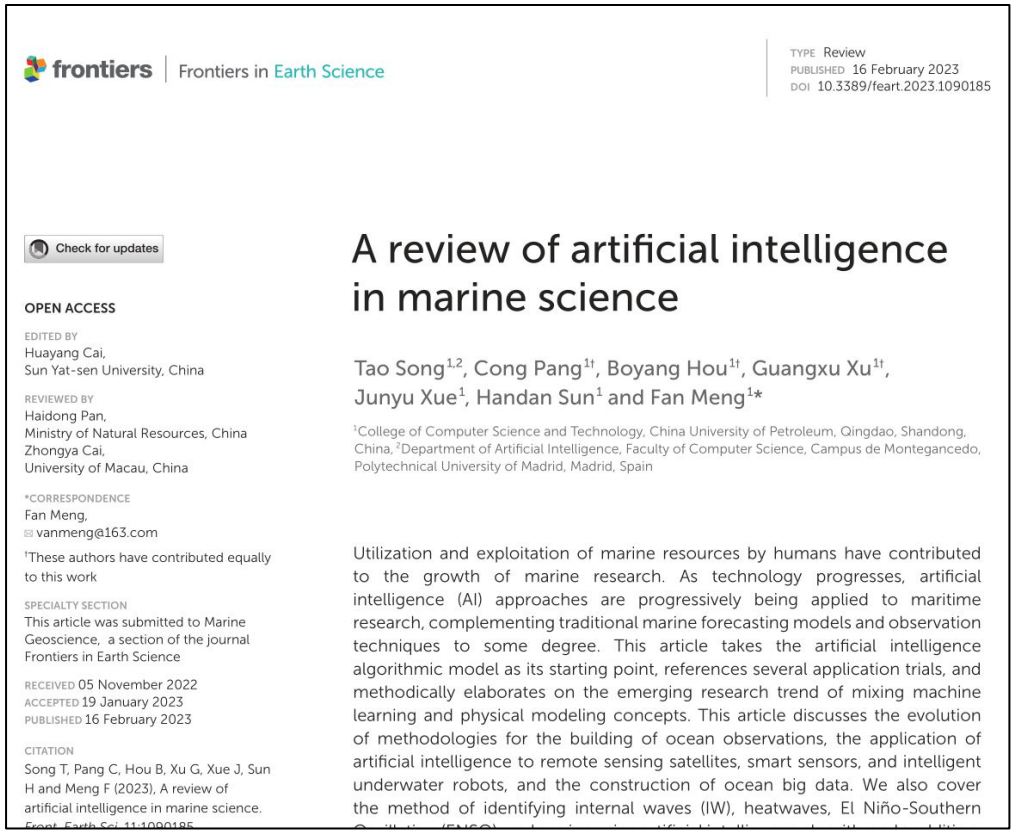
Generative AI

Modelos capazes de gerar dados, representações e outros conteúdos, incluindo modelos generativos baseados em DL.

Na oceanografia, os mais usados: classificação, reconstrução, previsão, assimilação e inferência de processos físicos.

Inteligência Artificial nas Ciências Marinhas

Song et al. (2023) — A review of artificial intelligence in marine science



frontiers | Frontiers in Earth Science

TYPE Review
PUBLISHED 16 February 2023
DOI 10.3389/feart.2023.1090185

Check for updates

OPEN ACCESS

EDITED BY
Huayang Cai,
Sun Yat-sen University, China

REVIEWED BY
Haidong Pan,
Ministry of Natural Resources, China
Zhongya Cai,
University of Macau, China

*CORRESPONDENCE
Fan Meng,
vanmeng@163.com

†These authors have contributed equally to this work

SPECIALTY SECTION
This article was submitted to Marine Geoscience, a section of the journal Frontiers in Earth Science

RECEIVED 05 November 2022
ACCEPTED 19 January 2023
PUBLISHED 16 February 2023

CITATION
Song T, Pang C, Hou B, Xu G, Xue J, Sun H and Meng F (2023), A review of artificial intelligence in marine science.

A review of artificial intelligence in marine science

Tao Song[1,2], Cong Pang[1†], Boyang Hou[1†], Guangxu Xu[1†], Junyu Xue[1], Handan Sun[1] and Fan Meng[1*]

[1]College of Computer Science and Technology, China University of Petroleum, Qingdao, Shandong, China, [2]Department of Artificial Intelligence, Faculty of Computer Science, Campus de Montegancedo, Polytechnical University of Madrid, Madrid, Spain

Utilization and exploitation of marine resources by humans have contributed to the growth of marine research. As technology progresses, artificial intelligence (AI) approaches are progressively being applied to maritime research, complementing traditional marine forecasting models and observation techniques to some degree. This article takes the artificial intelligence algorithmic model as its starting point, references several application trials, and methodically elaborates on the emerging research trend of mixing machine learning and physical modeling concepts. This article discusses the evolution of methodologies for the building of ocean observations, the application of artificial intelligence to remote sensing satellites, smart sensors, and intelligent underwater robots, and the construction of ocean big data. We also cover the method of identifying internal waves (IW), heatwaves, El Niño-Southern

Song et al. (2023), Frontiers in Earth Science.

DOI: 10.3389/feart.2023.1090185

A revisão organiza as aplicações de IA em três grandes domínios:

- **Ocean observations**: sensoriamento remoto, sensores inteligentes, robótica e reconstrução de dados.
- Ocean phenomena identification: ondas internas, ondas de calor, ENSO e gelo marinho.
- Ocean element forecasting: previsão de temperatura, salinidade, nível do mar, ondas e correntes.

Métodos destacados: Random Forest, ANN, CNN, RNN, LSTM e ConvLSTM.

Perspectiva: integração crescente entre métodos baseados em dados e modelagem física.

Deep Learning para Inferir a Dinâmica Oceânica

Manucharyan et al. (2026) — Deep Learning to Infer Ocean Dynamics



Home / A-Z Publications / Annual Review of Marine Science / Early Publication / Review in Advance

ANNUAL REVIEW OF MARINE SCIENCE

Review Article

Deep Learning to Infer Ocean Dynamics

Georgy E. Manucharyan[1], Scott A. Martin[1], Dhruv Balwada[2] and Jinbo Wang[3]

View Affiliations and Author Notes

Vol. 19 | https://doi.org/10.1146/annurev-marine-040324-023244

Review in Advance first posted online on September 08, 2026. (Changes may still occur before final publication.)

Copyright © 2027 by the author(s). All rights reserved

View Citation

Info Sections Get Access Tools Share

Abstract

Inferring ocean dynamics remains challenging due to the complexity of multiscale nonlinear interactions, sparsity of observations, and limitations of numerical models. Deep learning (DL) has emerged as a powerful data-driven framework that exploits nonlinear dependencies across heterogeneous datasets, complementing traditional approaches. Here, we review recent progress in applying DL to ocean dynamics, including spatiotemporal interpolation of satellite and in situ data, estimation of unobserved ocean variables, neural data assimilation, ocean forecasting, and the development of eddy parameterizations for hybrid models. DL methods have excelled at fusing multimodal

Manucharyan et al. (2026), Annual Review of Marine Science.

DOI: 10.1146/annurev-marine-040324-023244

Uma perspectiva mais especializada sobre as aplicações de DL à dinâmica oceânica:

- Reconstrução de campos oceânicos a partir de observações esparsas.
- Inferência de variáveis subsuperficiais não observadas diretamente.
- Neural Data Assimilation e modelos generativos.
- Previsão da evolução do estado oceânico.
- Parametrizações subgrade e modelos híbridos físico–neurais.

A questão científica evolui: de reconhecer padrões para inferir estados, processos e relações dinâmicas.

Uma Nova Fronteira: Previsão Oceânica com Deep Learning

De modelos para variáveis específicas à previsão do estado oceânico

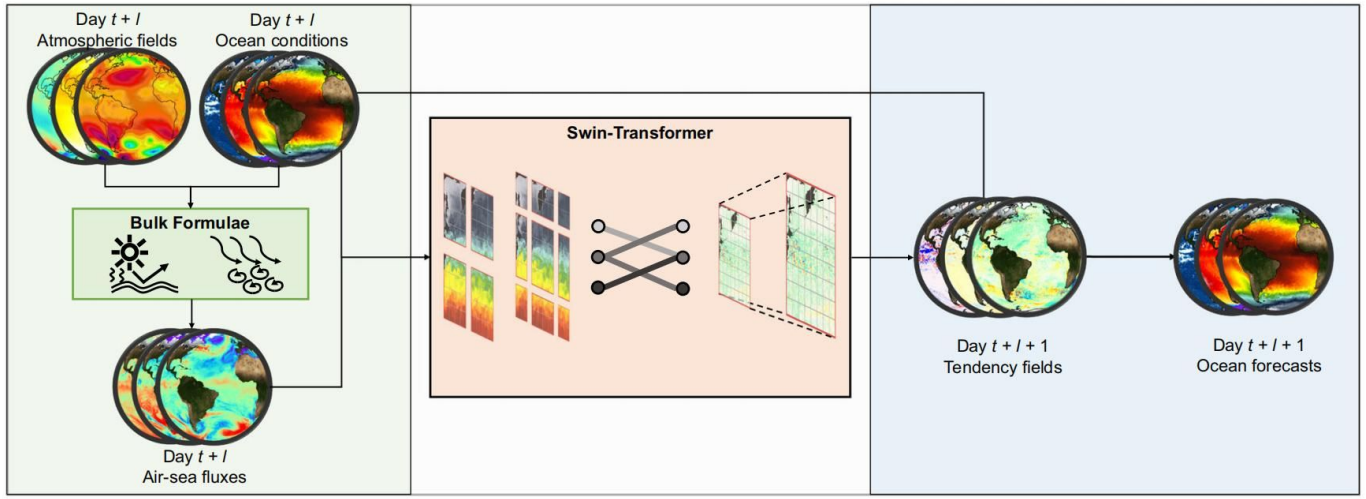
Exemplos recentes incluem WenHai, Samudra e métodos neurais de assimilação e reconstrução.

- Aprendizado da evolução espaço-temporal de campos oceânicos.
- Integração de condições oceânicas e forçantes atmosféricas.
- Emulação de modelos numéricos com menor custo de inferência.
- Possibilidade de ensembles, assimilação generativa e modelos híbridos.

Sistema	Objetivo principal	Abordagem
WenHai	Previsão oceânica de curto prazo	Swin Transformer e forçantes atmosféricas
Samudra	Emulação oceânica para clima	ConvNeXt U-Net
4DVarNet	Reconstrução e assimilação de observações esparsas	DL inspirado em 4D-Var
GenDA	Estimativa probabilística do estado oceânico	Modelos generativos de difusão
NeurOST	Reconstrução de SSH e correntes superficiais	Aprendizado com altimetria e SST
DINCAE 2.0	Reconstrução de observações incompletas	Autoencoder convolucional

Uma Nova Fronteira: Previsão Oceânica com Deep Learning

De modelos para variáveis específicas à previsão do estado oceânico



nature communications

Vie

Explore content | About the journal | Publish with us

nature › nature communications › articles › article

Article | Open access | Published: 06 March 2025

Forecasting the eddying ocean with a deep neural network

Yingzhe Cui, Ruohan Wu, Xiang Zhang, Ziqi Zhu, Bo Liu, Jun Shi, Junshi Chen, Hailong Liu, Shenghui Zhou, Liang Su, Zhao Jing, Hong An & Lixin Wu

Nature Communications **16**, Article number: 2268 (2025) | Cite this article

Save article

24k Accesses | **86** Citations | **4** Altmetric | Metrics

Abstract

Mesoscale eddies with horizontal scales from tens to hundreds of kilometers are ubiquitous in the upper ocean, dominating the ocean variability from daily to weekly time scales. Their turbulent nature causes great scientific challenges and computational burdens in accurately forecasting the short-term evolution of the ocean states based on conventional physics-driven numerical models. Recently, artificial intelligence (AI)-based methods have achieved competitive forecast performance and greatly increased computational efficiency in weather forecasts, compared to numerical models. Yet, their application to ocean forecasts remains challenging due to the different dynamic characteristics of the atmosphere and the ocean. Here, we develop WenHai, a data-driven eddy-resolving global ocean forecast system (GOFS), by training a deep

Uma Nova Fronteira: Previsão Oceânica com Deep Learning

De modelos para variáveis específicas à previsão do estado oceânico

AGU ADVANCING EARTH AND SPACE SCIENCES

Geophysical Research Letters

RESEARCH LETTER
10.1029/2024GL114318

Samudra: An AI Global Ocean Emulator for Climate

Surya Dheeshjith[1], Adam Subel[1], Alistair Adcroft[2], Julius Busecke[3], Carlos Fernandez-Granda[1,4], Shubham Gupta[1], and Laure Zanna[1,4]

[1]Courant Institute of Mathematical Sciences, New York University, New York, NY, USA, [2]Program in Atmospheric and Oceanic Sciences, Princeton University, Princeton, NJ, USA, [3]Lamont Doherty Earth Observatory, Columbia University, Palisades, NY, USA, [4]Center for Data Science, New York University, New York, NY, USA

Key Points:

- We develop a global, 3D, ocean autoregressive machine learning emulator for climate studies
- The emulator, based on a UNet architecture, is stable for centuries, producing accurate climatologies and variability of ocean variables
- The emulator training is robust to changes in seeds and initial conditions in the data

Supporting Information:

Supporting Information may be found in the online version of this article.

Correspondence to:

S. Dheeshjith,
sd5313@nyu.edu

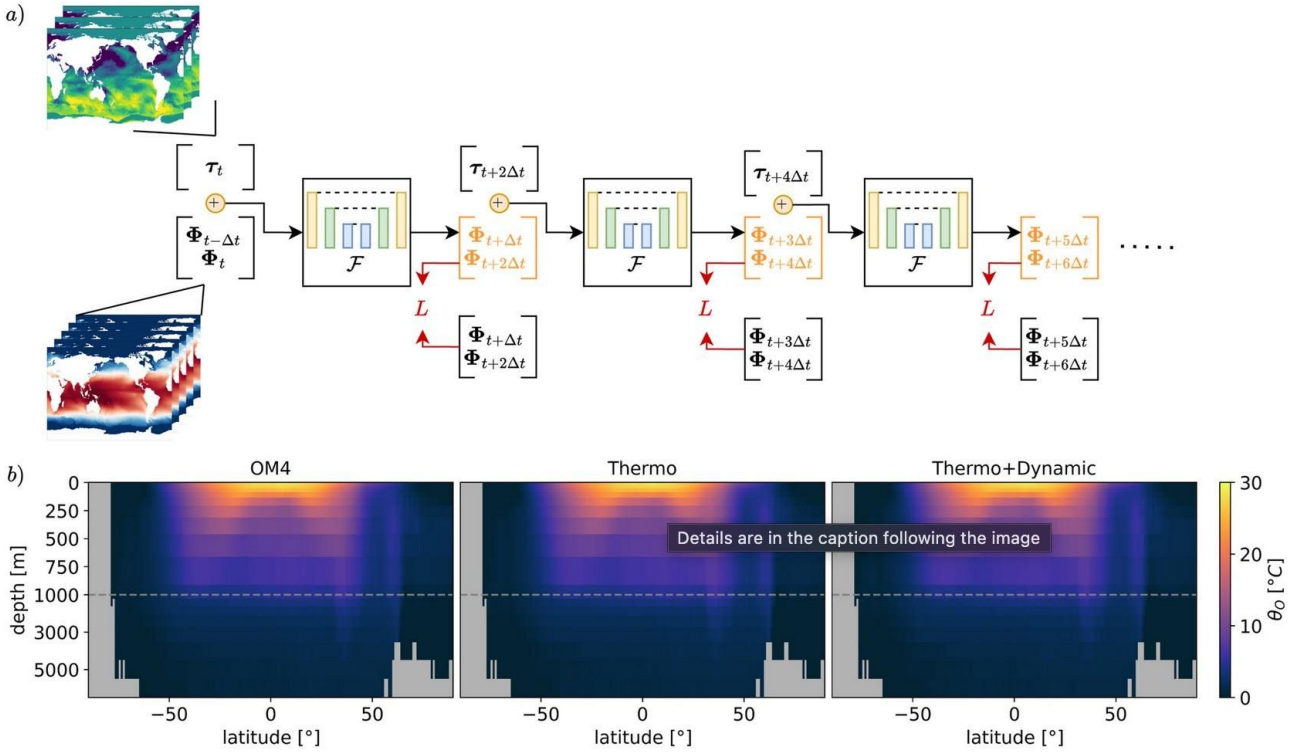
Citation:

Dheeshjith, S., Subel, A., Adcroft, A., Busecke, J., Fernandez-Granda, C., Gupta, S., & Zanna, L. (2025). Samudra: An AI global ocean emulator for climate. *Geophysical Research Letters*, *52*, e2024GL114318. https://doi.org/10.1029/2024GL114318

Received 16 DEC 2024
Accepted 15 MAY 2025

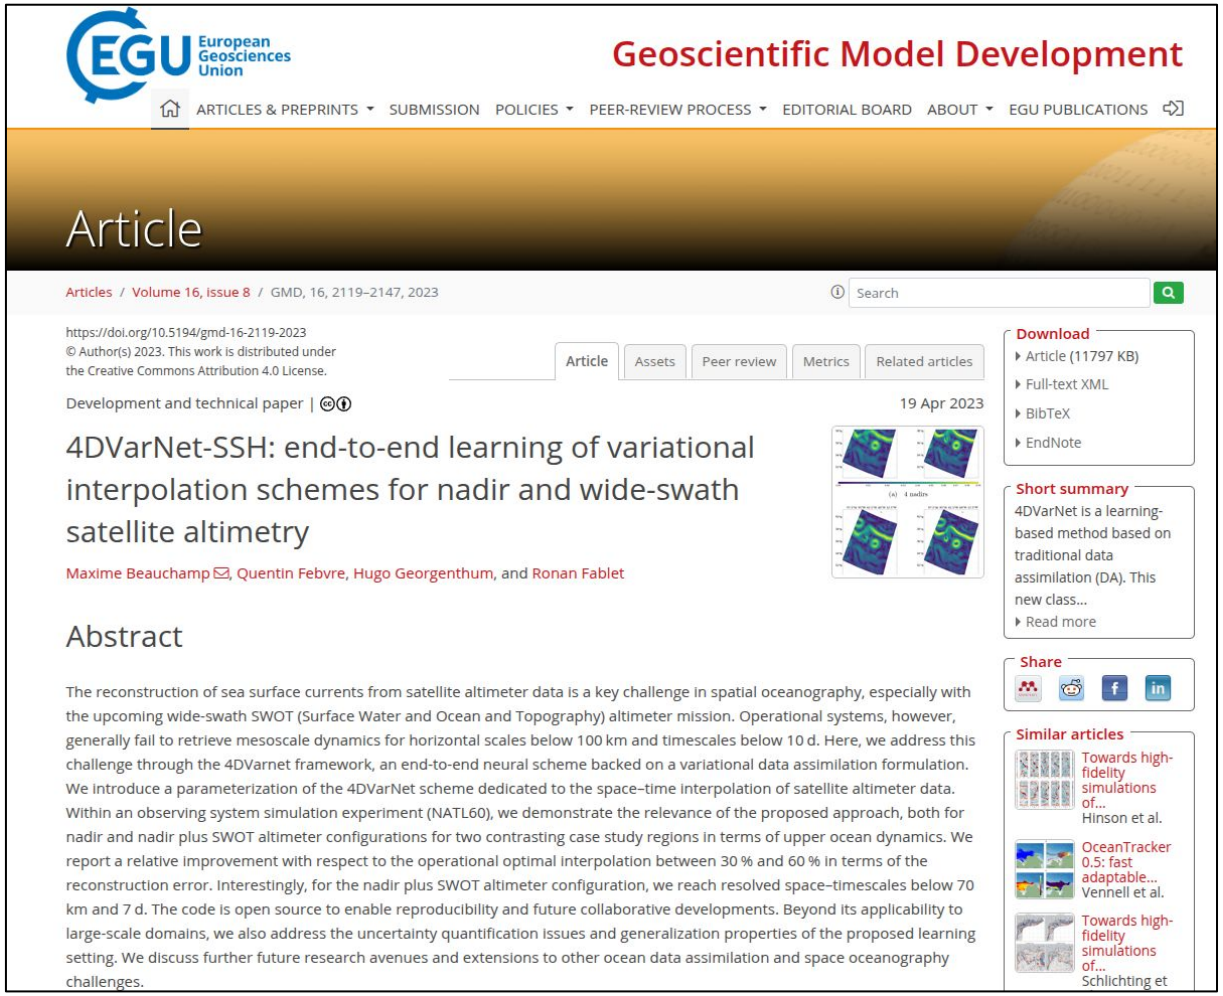
Abstract AI emulators for forecasting have emerged as powerful tools that can outperform conventional numerical predictions. The next frontier is to build emulators for long climate simulations with skill across a range of spatiotemporal scales, a particularly important goal for the ocean. Our work builds a skillful global emulator of the ocean component of a state-of-the-art climate model. We emulate key ocean variables, sea surface height, horizontal velocities, temperature, and salinity, across their full depth. We use a modified ConvNeXt UNet architecture trained on multi-depth levels of ocean data. We show that the ocean emulator—*Samudra*—which exhibits no drift relative to the truth, can reproduce the depth structure of ocean variables and their interannual variability. Samudra is stable for centuries and 150 times faster than the original ocean model. Samudra struggles to capture the correct magnitude of the forcing trends and simultaneously remain stable, requiring further work.

Plain Language Summary AI tools are extremely effective in making fast and accurate predictions on weather to seasonal timescales. Capturing decadal to centennial changes, which arise from ocean dynamics, remains an outstanding challenge. We built an advanced AI model called "Samudra" to simulate global ocean behavior. Samudra is trained on simulated data from a state-of-the-art ocean climate model and predicts key ocean features such as sea surface height, currents, temperature, and salinity throughout the ocean's depth. Samudra can accurately recreate patterns in ocean variables, including year-to-year changes. It is stable over centuries and is 150 times faster than traditional ocean models. However, Samudra still faces challenges in balancing stability with accurately predicting the effects of external factors (like climate trends), and further improvements are needed to address this limitation.



Uma Nova Fronteira: Previsão Oceânica com Deep Learning

De modelos para variáveis específicas à previsão do estado oceânico



European Geosciences Union

Geoscientific Model Development

ARTICLES & PREPRINTS · SUBMISSION · POLICIES · PEER-REVIEW PROCESS · EDITORIAL BOARD · ABOUT · EGU PUBLICATIONS

Article

Articles / Volume 16, issue 8 / GMD, 16, 2119–2147, 2023

Search

https://doi.org/10.5194/gmd-16-2119-2023
© Author(s) 2023. This work is distributed under the Creative Commons Attribution 4.0 License.

Article | Assets | Peer review | Metrics | Related articles

Development and technical paper | 19 Apr 2023

4DVarNet-SSH: end-to-end learning of variational interpolation schemes for nadir and wide-swath satellite altimetry

Maxime Beauchamp, Quentin Febvre, Hugo Georgenthum, and Ronan Fablet

Abstract

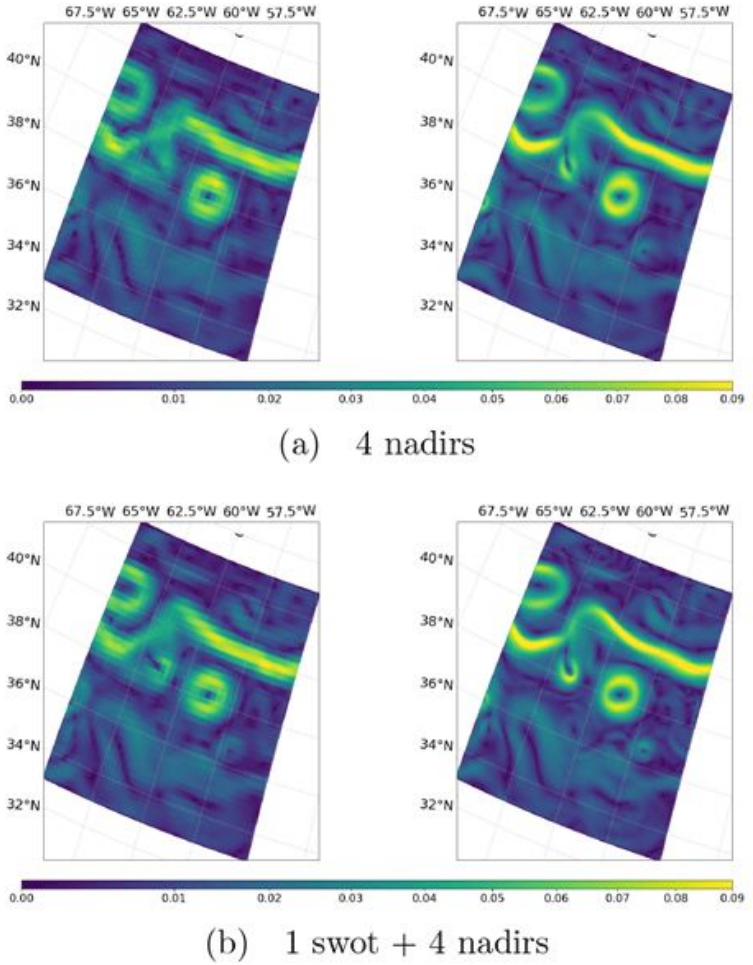
The reconstruction of sea surface currents from satellite altimeter data is a key challenge in spatial oceanography, especially with the upcoming wide-swath SWOT (Surface Water and Ocean and Topography) altimeter mission. Operational systems, however, generally fail to retrieve mesoscale dynamics for horizontal scales below 100 km and timescales below 10 d. Here, we address this challenge through the 4DVarnet framework, an end-to-end neural scheme backed on a variational data assimilation formulation. We introduce a parameterization of the 4DVarNet scheme dedicated to the space–time interpolation of satellite altimeter data. Within an observing system simulation experiment (NATL60), we demonstrate the relevance of the proposed approach, both for nadir and nadir plus SWOT altimeter configurations for two contrasting case study regions in terms of upper ocean dynamics. We report a relative improvement with respect to the operational optimal interpolation between 30 % and 60 % in terms of the reconstruction error. Interestingly, for the nadir plus SWOT altimeter configuration, we reach resolved space–timescales below 70 km and 7 d. The code is open source to enable reproducibility and future collaborative developments. Beyond its applicability to large-scale domains, we also address the uncertainty quantification issues and generalization properties of the proposed learning setting. We discuss further future research avenues and extensions to other ocean data assimilation and space oceanography challenges.

Download
- Article (11797 KB)
- Full-text XML
- BibTeX
- EndNote

Short summary
4DVarNet is a learning-based method based on traditional data assimilation (DA). This new class...
Read more

Share

Similar articles
- Towards high-fidelity simulations of... Hinson et al.
- OceanTracker 0.5: fast adaptable... Vennell et al.
- Towards high-fidelity simulations of... Schlichting et



Uma Nova Fronteira: Previsão Oceânica com Deep Learning

Desafios ainda abertos:

Conservação de massa, energia e momento.

Generalização para condições não observadas.

Propagação de vieses e quantificação de incertezas (forte em estatística)

Validação orientada aos processos físicos (Ex: PINN Physics-Informed Neural Network)

Referência: Manucharyan et al. (2026).

Exemplo WenHai: Cui et al. (2025).

Mapeando ML/DL na Oceanografia: Nosso Levantamento

Revisão bibliográfica e bibliométrica em andamento

Objetivo: identificar como, onde e com quais métodos a IA vem sendo aplicada à oceanografia, com atenção especial à produção brasileira.

Fontes internacionais

OpenAlex, Crossref, Scopus e outras bases bibliográficas; SciSpace como ferramenta complementar de pesquisa e extração.

Fontes brasileiras

SciELO, BDTD e Catálogo de Teses e Dissertações da CAPES.

Dimensões analisadas

- Evolução temporal e distribuição institucional.
- Domínios de aplicação oceanográfica.
- Métodos de ML/DL empregados.
- Publicações científicas e literatura acadêmica não publicada em periódicos.



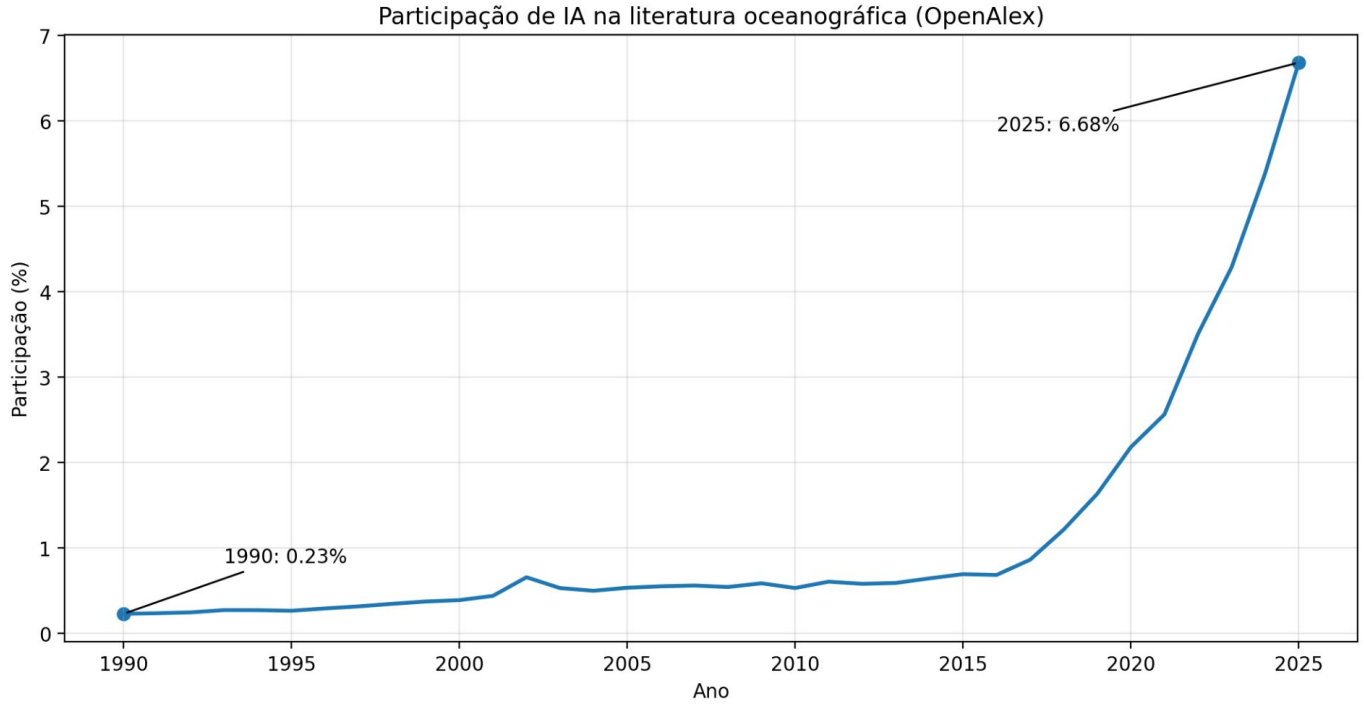
Recorte principal: 2016–2026.

Resultados exploratórios, com classificações automáticas ainda não validadas manualmente.

A IA Está Ganhando Espaço na Literatura Oceanográfica

Uma tendência de crescimento identificada no OpenAlex

Participação de registros identificados por termos de IA no domínio oceanográfico consultado:



Fonte: AI_in_Oceanography / OpenAlex. Série histórica 1990–2025 baseada no arquivo openalex_annual_counts_normalised.csv. Indicador exploratório dependente da estratégia de busca.

- A participação relativa identificada cresceu aproximadamente 29 vezes nesse intervalo.
- O levantamento também indica maior presença de aplicações recentes de ML/DL em diferentes domínios oceanográficos.
- **Importante**: os indicadores refletem a estratégia de busca e classificação utilizada, não uma medida exaustiva de toda a produção mundial.

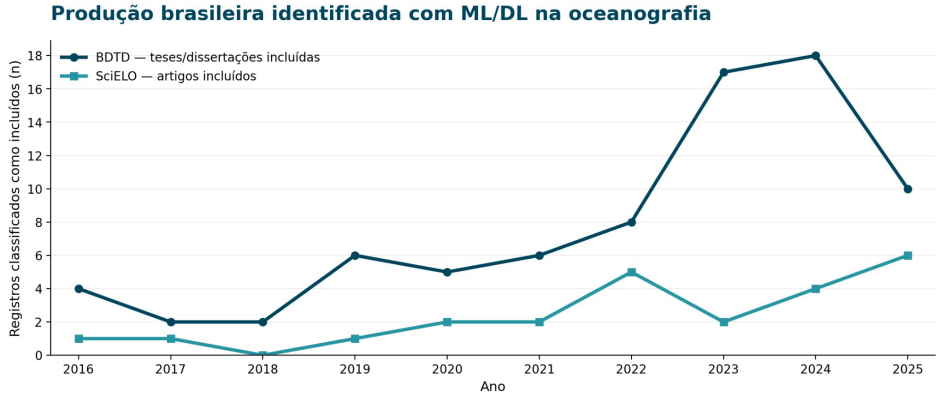
Fonte: AI_in_Oceanography, levantamento exploratório OpenAlex, 2026.

E no Brasil? Artigos, Teses e Dissertações

Resultados preliminares do levantamento nacional

Registros classificados automaticamente como relevantes:

- SciELO: 48 incluídos (e 15 limítrofes).
- BDTD: 102 incluídos (e 52 limítrofes).
- CAPES: 266 candidatos centrais identificados no recorte analisado.



Fonte: AI_in_Oceanography (SciELO via OpenAlex; BDTD). Classificação automática exploratória, sem validação humana.
Séries com cobertura e estratégias de recuperação diferentes; 2025 pode estar sujeito a atraso de indexação.

O levantamento evidencia uma produção acadêmica distribuída entre periódicos, programas de pós-graduação e instituições brasileiras, porém….

Uma questão essencial:

Qual é a visibilidade dessa produção nos periódicos científicos nacionais e internacionais?

Estamos acompanhando o crescimento internacional?

Os registros brasileiros indicam expansão recente de ML/DL, especialmente em teses e dissertações. Entretanto, ainda não sabemos se esse crescimento acompanha o ritmo global. A comparação exige identificar a produção brasileira em periódicos internacionais e normalizar os indicadores.

Onde Estamos Aplicando ML/DL?

Distribuição temática nos registros brasileiros recuperados (2016 á 2025)

Domínio	SciELO (n=48)	BDTD (n=102)
Sensoriamento remoto	43,8%	34,3%
Oceanografia geológica	25,0%	32,4%
Oceanografia física	29,2%	22,5%
Modelagem e previsão oceânica	8,3%	11,8%
Assimilação de dados	0%	1,0%

Indicação preliminar: sensoriamento remoto e aplicações associadas à análise de padrões apresentam maior representação do que modelagem, previsão e assimilação.

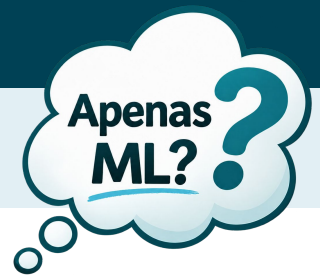
Categorias multirrótulo; classificação automática não validada manualmente.

Fonte: AI_in_Oceanography, SciELO/BDTD, 2026.

Quais Métodos Estamos Utilizando?

Métodos frequentes nos registros brasileiros classificados (2016 à 2025)

Método	SciELO	BDTD
ANN / MLP	23	34
Random Forest	8	18
CNN	4	17



Predominam, entre os métodos identificados, técnicas estabelecidas de classificação, regressão e reconhecimento de padrões. Essas técnicas continuam cientificamente relevantes, mas sua frequência não representa, isoladamente, o grau de avanço metodológico.

Contagens automáticas, não exclusivas e ainda não validadas.

Fonte: AI_in_Oceanography, 2026.

Quais Métodos Estamos Utilizando?

Questões para investigação do GT5

Qual é a presença de modelos neurais híbridos e physics-informed? (PINNs)

Quanto se desenvolve em assimilação neural e previsão dinâmica?

Os métodos são avaliados quanto à generalização e consistência física?

GT5 ReNOMO: Competências e Oportunidades

Um grupo transversal: observação, modelagem, tecnologia e ciência de dados

Contribuições recebidas no levantamento inicial da comunidade:

EPAGRI — Luis Garbossa

- Modelagem hidrodinâmica operacional e monitoramento costeiro.
- Interesse em ML/DL para aquicultura, previsão e correção de viés.
- Protótipo MohidParticleBot e aplicações de LLMs para acesso à informação ambiental.

UFSC — Pedro Veras Guimarães

- Deep Learning em fenômenos hidrodinâmicos e mecânica dos fluidos.
- Classificação de quebra de ondas.
- Computação de alto desempenho e agentic AI aplicada ao desenvolvimento científico.

Demais instituições participantes

UFF, UFES, UERJ, UNIFAP, IEAPM e outras, com competências ainda em mapeamento.

Oportunidade: conectar experiências existentes e estimular aplicações científicas colaborativas entre os GTs.

Para Onde Devemos Avançar?

Do uso pontual de algoritmos à consolidação de competências científicas

INCT ReNOMO
REDE NACIONAL DE OBSERVAÇÃO E MONITORAMENTO OCEÂNICO

1. Formação especializada — GT5 + GT4 de Educação

Capacitação em ML/DL aplicado à oceanografia, com ênfase em dinâmica, previsão, assimilação, validação e reprodutibilidade.

2. Integração científica e tecnológica

Projetos-piloto interinstitucionais conectando observações, sensoriamento remoto, modelos numéricos e métodos modernos de IA.

Para Onde Devemos Avançar?

Prioridades estratégicas para o GT5

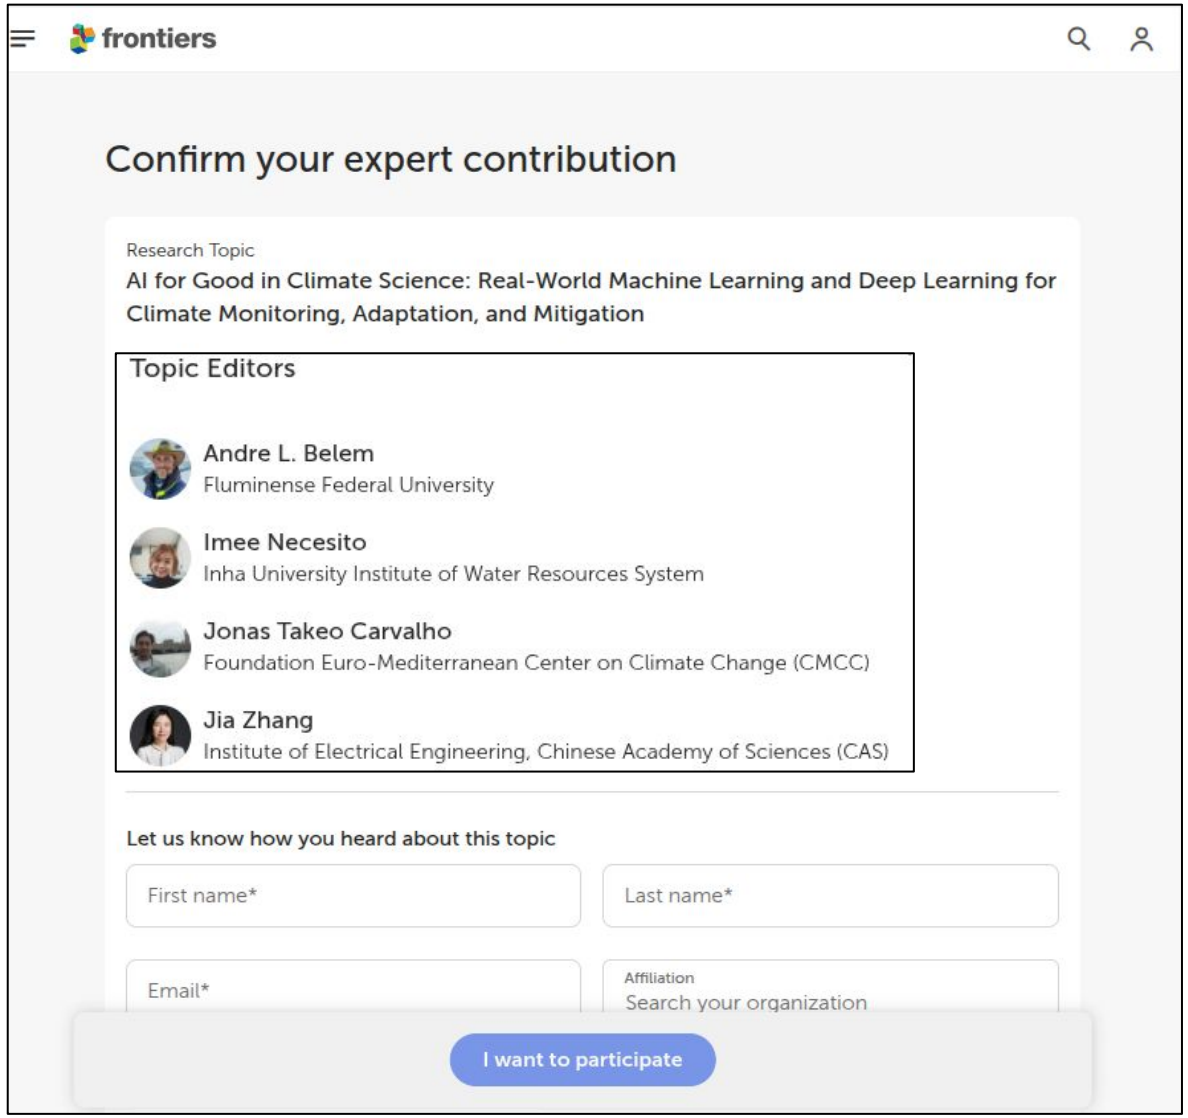
3. Produção e visibilidade científica

Mapear a literatura cinza, investigar sua relação com artigos publicados, estimular publicações revisadas por pares e compartilhar dados, códigos e workflows.

4. Continuidade do levantamento

Consolidar a revisão sistemática, validar classificações e estabelecer um mapa atualizado das competências brasileiras.

Para Onde Devemos Avançar?



AI for Good in Climate Science: Real-World Machine Learning and Deep Learning for Climate Monitoring, Adaptation, and Mitigation

3.9	7.7	16,332
Impact Factor	CiteScore	Citations

Mensagem final

O desafio não é simplesmente utilizar mais Machine Learning (ou IA), mas desenvolver **capacidade científica** para compreender, modelar e prever o oceano com métodos robustos, integrados à física e efetivamente compartilhados pela comunidade.

INCT ReNOMO — GT5 | 2026